



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт кибербезопасности и цифровых технологий  
(наименование института, филиала)

Кафедра информатики  
(наименование кафедры)

## КУРСОВАЯ РАБОТА

по дисциплине

Основы машинного обучения  
(наименование дисциплины)

Тема курсовой работы  
тональности.

Реализация алгоритма классификации отзывов о фильмах по

Студент группы

БФБО-02-25, Макаров Максим Львович  
(учебная группа, фамилия, имя, отчество студента)

  
(подпись студента)

Руководитель курсовой  
работы

доцент, к.ф.-м.н., доцент, Шмелева А.Г.  
(должность, звание, ученая степень, ФИО)

  
(подпись руководителя)

Рецензент(при наличии)


—  
(должность, звание, учёная степень)

—  
(подпись рецензента)

Работа представлена к защите «24» мая 2026 г.

Допущен к защите

«24» мая 2026 г.

Отлично  Шмелева А.Г.  
09.06.26



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение  
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт кибербезопасности и цифровых технологий  
(наименование института, филиала)

Кафедра информатики  
(наименование кафедры)

Утверждаю

заведующий кафедрой информатики

Лебедев О.Б.  
ФИО

Подпись

« 26 » 02 2026 г.

### ЗАДАНИЕ

на выполнение курсовой работы по дисциплине

«Основы машинного обучения»

Студент Макаров Максим Львович

Группа БФБО-02-25

Тема « Реализация алгоритма классификации отзывов о фильмах по тональности. »

Исходные данные: Веб-приложение, предназначенное для создания и редактирования интерактивных блокнотов “джупитер ноутбук”, язык программирования “пайтон”, найденный в открытом доступе датасет с оценками фильмов.

Перечень вопросов, подлежащих разработке, и обязательного графического материала: Анализ предметной области, выбор и подготовка данных, разработка модели, обучение и оценка модели, анализ результатов, оптимизация и улучшение, применение и перспективы.

Срок предоставления к защите курсового проекта (работы) до « 24 » 05 2026 г.

Задание на курсовой проект (работу) выдал

(Шмелева А.Г.)

Подпись руководителя

Ф.И.О. руководителя

« 26 » 02

2026 г. Задание на курсовой проект (работу) получил

(Макаров М.Л.)

Подпись обучающегося Ф.И.О. исполнителя

## Оглавление

|                                                        |    |
|--------------------------------------------------------|----|
| Введение.....                                          | 3  |
| 1. Теоретические основы .....                          | 6  |
| 1.1. Исторический контекст .....                       | 7  |
| 1.2. Основные понятия и определения .....              | 7  |
| 1.3. Датасеты для анализа тональности отзывов .....    | 8  |
| 1.4. Основные подходы к решению задачи .....           | 8  |
| 1.5. Представление текста в числовом виде.....         | 9  |
| 1.6. Алгоритмы классификации текстов .....             | 9  |
| 1.7. Метрики оценки качества классификации .....       | 10 |
| 2. Практическая реализация классификации отзывов ..... | 10 |
| 2.1. Описание используемого датасета.....              | 11 |
| 2.2. Подготовка обучающей и тестовой выборок.....      | 11 |
| 2.3. Преобразование текстовых данных .....             | 11 |
| Заключение .....                                       | 12 |
| Список использованных источников.....                  | 13 |
| Приложение 1. Листинг программы .....                  | 14 |

## Введение

В эпоху цифровых технологий и стремительного развития платформ по распространению видеоконтента значительно возрос объём пользовательских отзывов о кинематографических произведениях. Миллионы зрителей ежедневно оставляют текстовые отзывы на специализированных ресурсах, таких как IMDb, Rotten Tomatoes, Metacritic и других крупных агрегаторах. Эти отзывы представляют собой ценный источник информации о восприятии фильмов аудиторией и содержат эмоциональную оценку различных аспектов кинопроизведения.

Анализ такого большого массива неструктурированных текстовых данных вручную является крайне трудоёмким и практически невозможным. В связи с этим особую актуальность приобретает задача автоматической классификации отзывов по тональности (sentiment analysis), позволяющая определять преобладающую эмоциональную окраску текста. В рамках данной работы рассматривается задача бинарной классификации отзывов, при которой каждому тексту присваивается один из двух классов: положительный или отрицательный.

**Актуальность** исследования обусловлена возрастающей потребностью киноиндустрии, стриминговых сервисов и маркетинговых агентств в оперативном и объективном анализе общественного мнения о выпускаемых фильмах. Автоматическая оценка тональности отзывов даёт возможность своевременно выявлять сильные и слабые стороны кинопродукта, корректировать маркетинговые стратегии, прогнозировать коммерческий успех и улучшать качество рекомендационных систем. Кроме того, развитие методов обработки естественного языка открывает новые перспективы для повышения точности анализа англоязычных отзывов, которые составляют значительную долю глобального пользовательского контента.

**Практическая значимость** работы заключается в том, что разработанная модель может быть использована для автоматического анализа пользовательских отзывов, предварительной оценки реакции аудитории на фильм, а также как часть рекомендательных и аналитических систем.

**Цель** курсовой работы заключается в разработке и реализации алгоритма классификации отзывов о фильмах по тональности на основе методов машинного обучения.

Для достижения поставленной цели необходимо решить следующие **задачи**:

1. Изучить теоретические основы анализа тональности текста и современные подходы к решению задачи.
2. Проанализировать особенности англоязычных отзывов о фильмах и характерные для них лингвистические явления.
3. Выбрать и обосновать использование подходящего датасета отзывов о фильмах на английском языке.
4. Выполнить предобработку текстовых данных, включая токенизацию, нормализацию, удаление шумов и векторизацию.
5. Реализовать и сравнить эффективность нескольких классических алгоритмов машинного обучения для классификации отзывов по тональности.
6. Провести экспериментальную оценку качества разработанных моделей с использованием стандартных метрик классификации.
7. Сформулировать выводы о применимости и эффективности реализованных подходов для анализа тональности отзывов о фильмах.

**Объект исследования** — англоязычные отзывы пользователей о художественных фильмах.

**Предмет исследования** — алгоритмы и модели машинного обучения для автоматической классификации тональности текстовых отзывов.

**Методы исследования** включают анализ научной литературы, методы предобработки естественного языка (NLP), алгоритмы машинного обучения и глубокого обучения, а также статистические методы оценки качества моделей. В качестве программных средств используются язык программирования Python, интерактивная среда Jupyter Notebook, библиотеки pandas, scikit-learn и средства визуализации данных.

Работа состоит из введения, двух глав, заключения, списка использованных источников и приложений. В первой главе рассматриваются теоретические аспекты анализа тональности. Во второй главе описывается выбранный датасет, процесс предобработки данных и анализ полученных результатов.

Таким образом, разработка эффективного алгоритма классификации отзывов о фильмах по тональности представляет значительный теоретический и практический интерес и способствует решению актуальных задач в области обработки естественного языка и анализа пользовательских предпочтений в кинематографе.

## **1. Теоретические основы**

### **1.1. Исторический контекст**

Задача анализа тональности отзывов о фильмах активно изучается ещё с начала 2000-х годов. Одними из первых работ стали исследования Bo Pang, Lillian Lee и Shivakumar Vaithyanathan (2002)[1], в которых были применены методы машинного обучения к классификации отзывов с IMDb и Rotten Tomatoes. Дальнейшее развитие произошло с появлением моделей глубокого обучения в 2012–2013 годов. Особенно заметный прогресс обеспечило использование предобученных трансформерных моделей, таких как BERT (Devlin et al., 2019)[2], благодаря которым точность бинарной классификации на стандартных бенчмарках достигала 90–95% и выше.

### **1.2. Основные понятия и определения**

Sentiment Analysis (анализ тональности, или анализ сентимента) — это задача обработки естественного языка (NLP), направленная на автоматическое определение эмоциональной окраски текста: положительной или отрицательной.

Обработка естественного языка (Natural Language Processing, NLP) — это раздел искусственного интеллекта и компьютерных наук, занимающийся разработкой методов и алгоритмов, позволяющих компьютерам понимать, анализировать, интерпретировать и генерировать текст и речь на естественных человеческих языках.

В контексте отзывов о фильмах классификация чаще всего является бинарной (positive/negative), хотя существуют задачи с многоклассовой классификацией (включая neutral) и aspect-based sentiment analysis (выделение тональности по отдельным аспектам фильма: сюжет, актёрская игра, визуальные эффекты и т. д.).

### **1.3. Датасеты для анализа тональности отзывов**

В данной работе используется датасет IMDb Dataset of 50K Movie Reviews, содержащий 50 000 англоязычных отзывов о фильмах. Каждый отзыв имеет би-

нарную разметку тональности: `positive` или `negative`, что позволяет рассматривать задачу как задачу бинарной классификации текста. В используемой версии данные представлены в виде единого CSV-файла, поэтому разделение на обучающую и тестовую выборки выполняется самостоятельно средствами языка Python. Данный датасет выбран, поскольку он является одним из популярных наборов данных для решения задач анализа тональности и содержит достаточный объём текстов для обучения и оценки моделей машинного обучения.

Cornell Movie Review Data (polarity dataset v2.0): коллекция отзывов с разметкой по общей полярности и субъективности/объективности.

Rotten Tomatoes Sentiment Analysis Dataset: часто используется для многоклассовой классификации (от 0 до 4 баллов по тональности).

#### **1.4. Основные подходы к решению задачи**

Классические методы машинного обучения: Bag-of-Words (BoW), TF-IDF, n-grams в сочетании с алгоритмами Naïve Bayes, Support Vector Machines (SVM), Logistic Regression, Random Forest. В работе будут использованы методы Naïve Bayes, Logistic Regression и Linear Support Vector Classification, так как они хорошо подходят для задач классификации текстов после преобразования документов в числовое представление с помощью Bag-of-Words или TF-IDF.

Методы на основе глубокого обучения: Recurrent Neural Networks (RNN), Long Short-Term Memory (LSTM), Bidirectional LSTM, а также предобученные трансформерные модели (BERT и его варианты), которые показывают state-of-the-art результаты на датасетах отзывов о фильмах.

Гибридные подходы: сочетание лексиконов (например, VADER, SentiWordNet) с машинным обучением.

#### **1.5. Представление текста в числовом виде**

Большинство алгоритмов машинного обучения не могут напрямую работать с текстовыми данными, поэтому перед обучением необходимо преобразовать текст в числовой вид. Одним из простейших подходов является модель «мешка слов» — Bag-of-Words. В этом подходе каждый документ



представляется вектором, элементы которого соответствуют словам из словаря, а значения отражают частоту появления слов в тексте. Более информативным способом является TF-IDF, учитывающий не только частоту слова в конкретном документе, но и его распространённость во всём корпусе. Благодаря этому часто встречающиеся, но малоинформативные слова получают меньший вес.

### 1.6. Алгоритмы классификации текстов

Для решения задачи классификации отзывов по тональности применяются классические алгоритмы машинного обучения. После преобразования текста в числовой вид с помощью Bag-of-Words или TF-IDF каждый отзыв представляется вектором признаков, который передаётся на вход классификатору.

В данной работе рассматриваются три метода: **Multinomial Naive Bayes**, **Logistic Regression** и **Linear Support Vector Classification**. Multinomial Naive Bayes оценивает вероятность принадлежности текста к определённому классу на основе частот встречаемости слов. Logistic Regression обучает веса признаков и определяет вероятность принадлежности отзыва к положительному или отрицательному классу. LinearSVC строит разделяющую гиперплоскость между классами в пространстве признаков и хорошо подходит для данных с большим количеством признаков.

Выбранные алгоритмы позволяют сравнить вероятностный подход, линейную модель классификации и метод опорных векторов при решении задачи анализа тональности отзывов о фильмах.

### 1.7. Метрики оценки качества классификации

Для оценки качества моделей классификации в работе используются accuracy, classification report и confusion matrix. Accuracy показывает долю правильно классифицированных отзывов среди всех объектов тестовой выборки. Classification report содержит более подробную информацию о качестве классификации по каждому классу, включая precision, recall и F1-score. Confusion matrix, или матрица ошибок, позволяет увидеть количество верно и неверно классифицированных отзывов для положительного и отрицательного классов.

Использование этих метрик позволяет не только определить общую точность модели, но и проанализировать характер ошибок классификатора. Это важно, поскольку две модели с одинаковой ассигасу могут по-разному ошибаться при определении положительных и отрицательных отзывов.

## **2. Практическая реализация классификации отзывов**

### **2.1. Описание используемого датасета**

В практической части работы используется датасет IMDb Dataset of 50K Movie Reviews, содержащий 50 000 англоязычных отзывов о фильмах. Каждый объект датасета представляет собой текстовый отзыв и соответствующую ему метку тональности: `positive` или `negative`. Таким образом, решаемая задача относится к бинарной классификации текста.

Данные были загружены из CSV-файла с помощью библиотеки `pandas`. Исходный датасет содержит два основных столбца: `review`, в котором находится текст отзыва, и `sentiment`, содержащий класс тональности. Для удобства дальнейшей обработки был создан дополнительный числовой столбец `p/n`, где положительным отзывам соответствует значение 1, а отрицательным — значение 0.

### **2.2. Подготовка обучающей и тестовой выборки**

Перед обучением моделей исходный датасет был разделён на обучающую и тестовую выборки с помощью функции `train_test_split` из библиотеки `scikit-learn`. Обучающая выборка используется для обучения моделей, а тестовая — для проверки качества классификации на данных, которые модель ранее не видела.

При разделении данных использовался параметр `stratify`, позволяющий сохранить одинаковое соотношение положительных и отрицательных отзывов в обучающей и тестовой выборках. Это важно для корректной оценки качества модели, так как при несбалансированном разделении одна из тональностей могла бы быть представлена значительно чаще другой.

В работе использовалось разделение датасета на две равные части: 50% данных для обучения и 50% данных для тестирования. В результате обучающая и тестовая выборки содержат по 25 000 отзывов.

### **2.3. Преобразование текстовых данных**

Так как алгоритмы машинного обучения не могут напрямую работать с текстом, отзывы необходимо преобразовать в числовой вид. Для этого в работе использовались методы векторизации текста: `CountVectorizer` и `TfidfVectorizer`.

CountVectorizer преобразует текст в матрицу частот слов, где каждому слову соответствует отдельный признак. Значение признака показывает, сколько раз слово встречается в конкретном отзыве. Такой подход используется в модели наивного Байеса и в модели LinearSVC.

TfidfVectorizer учитывает не только частоту слова в конкретном документе, но и его распространённость во всём корпусе текстов. Благодаря этому часто встречающиеся, но менее информативные слова получают меньший вес. Данный способ векторизации был использован при обучении модели логистической регрессии.

Для упрощения реализации применялся объект Pipeline, который объединяет этап векторизации текста и сам алгоритм классификации в одну последовательность. Это позволяет передавать модели исходные текстовые отзывы, а преобразование в числовой вид выполняется автоматически внутри pipeline.

## **2.4. Обучение модели Multinomial Naive Bayes**

Первой была обучена модель Multinomial Naive Bayes. Данный алгоритм часто применяется в задачах текстовой классификации, так как хорошо работает с признаками, основанными на частотах слов. В качестве метода векторизации для этой модели использовался CountVectorizer.

После обучения модель была проверена на тестовой выборке. Значение accuracy составило 0.8434, то есть модель правильно классифицировала около 84% отзывов. Согласно classification report, качество классификации оказалось достаточно сбалансированным для обоих классов. Матрица ошибок показала, что модель немного лучше определяет отрицательные отзывы, чем положительные.

Матрица ошибок модели Multinomial Naive Bayes представлена на рисунке 2.1.




Рисунок 2.1 — Матрица ошибок модели Multinomial Naive Bayes

## 2.5. Обучение модели Logistic Regression

Второй моделью была Logistic Regression. Несмотря на название, логистическая регрессия применяется для решения задач классификации. В данной работе она используется для определения вероятности принадлежности отзыва к положительному или отрицательному классу.

Для данной модели применялся TfidfVectorizer, так как TF-IDF-представление позволяет учитывать важность слов в тексте. После обучения и проверки на тестовой выборке модель показала ассурасу, равную 0.88968. Это лучший результат среди рассмотренных моделей.

Classification report показал, что значения precision, recall и F1-score для обоих классов находятся примерно на одном уровне и составляют около 0.89. Это говорит о том, что модель одинаково хорошо справляется как с положительными, так и с отрицательными отзывами.

Матрица ошибок модели Logistic Regression представлена на рисунке 2.2.




Рисунок 2.2 — Матрица ошибок модели Logistic Regression

## 2.6. Обучение модели Linear Support Vector Classification

Третьей была обучена модель Linear Support Vector Classification. Данный алгоритм строит разделяющую гиперплоскость между классами в пространстве признаков и хорошо подходит для задач классификации текстов, где количество признаков может быть очень большим.

В работе модель LinearSVC использовалась совместно с CountVectorizer. После обучения на тестовой выборке было получено значение accuracy, равное 0.86552. Этот результат выше, чем у модели Multinomial Naive Bayes, но ниже, чем у Logistic Regression.

Во время обучения модели было получено предупреждение о том, что алгоритм не достиг полной сходимости. Это означает, что для улучшения результата можно увеличить количество итераций обучения с помощью параметра `max_iter` или изменить способ векторизации текста, например использовать `TfidfVectorizer`.

Матрица ошибок модели LinearSVC представлена на рисунке 2.3.




Рисунок 2.3 — Матрица ошибок модели LinearSVC

## 2.7. Сравнение результатов моделей

Для оценки качества моделей использовались accuracy, classification report и confusion matrix. Accuracy показывает общую долю правильно классифицированных отзывов, classification report позволяет оценить precision, recall и F1-score для каждого класса, а confusion matrix показывает количество правильных и ошибочных предсказаний.

По результатам экспериментов были получены следующие значения accuracy:

Таблица 2.1 — Значения accuracy для каждой модели

| Модель                  | Векторизация    | Accuracy |
|-------------------------|-----------------|----------|
| Multinomial Naive Bayes | CountVectorizer | 0.8434   |
| Logistic Regression     | TfidfVectorizer | 0.88968  |
| LinearSVC               | CountVectorizer | 0.86552  |

Наилучший результат показала модель Logistic Regression с использованием TfidfVectorizer. Это можно объяснить тем, что TF-IDF-представление

лучше отражает значимость слов в тексте, а логистическая регрессия хорошо работает с разреженными текстовыми признаками.

Модель LinearSVC также показала достаточно высокий результат, однако уступила логистической регрессии. Модель Multinomial Naive Bayes оказалась самой простой и быстрой, но её точность ниже по сравнению с двумя другими алгоритмами.



## Заключение

В ходе выполнения курсовой работы была рассмотрена задача автоматической классификации отзывов о фильмах по тональности. Для решения данной задачи был использован датасет IMDb Dataset of 50K Movie Reviews, содержащий англоязычные отзывы с бинарной разметкой: положительной и отрицательной.

В теоретической части были рассмотрены основные понятия анализа тональности текста, методы представления текстовых данных в числовом виде, а также алгоритмы машинного обучения, применяемые для классификации текстов. В практической части был выполнен этап подготовки данных, включающий кодирование меток классов, разделение датасета на обучающую и тестовую выборки, а также векторизацию текстов с помощью CountVectorizer и TfidfVectorizer.

В ходе экспериментов были реализованы и сравнены три модели классификации: Multinomial Naive Bayes, Logistic Regression и LinearSVC. Оценка качества моделей проводилась с использованием accuracy, classification report и confusion matrix. По результатам экспериментов наилучшее качество показала модель Logistic Regression, достигшая accuracy 0.88968. Это позволяет сделать вывод, что логистическая регрессия в сочетании с TF-IDF-векторизацией является наиболее эффективным из рассмотренных подходов для решения задачи классификации отзывов о фильмах по тональности.

Таким образом, цель курсовой работы была достигнута: был реализован алгоритм классификации отзывов о фильмах по тональности, проведено обучение моделей и выполнена оценка их качества. Полученные результаты подтверждают, что классические методы машинного обучения могут успешно применяться для анализа тональности текстовых отзывов.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1.

1. Pang B., Lee L., Vaithyanathan S. Thumbs up? Sentiment Classification using Machine Learning Techniques // Proceedings of the 2002 Conference on Empirical Methods in Natural Language Processing (EMNLP 2002). 2002. P. 79-86.

2.

2. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // NAACL-HLT. 2019.

3. 3. Scikit-learn developers. CountVectorizer: convert a collection of text documents to a matrix of token counts [Электронный ресурс]. URL: [https://scikit-learn.org/stable/modules/generated/sklearn.feature\\_extraction.text.CountVectorizer.html](https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.CountVectorizer.html)

4. 4. Scikit-learn developers. LogisticRegression: scikit-learn documentation [Электронный ресурс]. URL: [https://scikit-learn.org/stable/modules/generated/sklearn.linear\\_model.LogisticRegression.html](https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html)

5. 5. Scikit-learn developers. LinearSVC: Linear Support Vector Classification [Электронный ресурс]. URL: <https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html>

## Приложение 1.

### Листинг программы

В приложении представлен программный код, использованный для загрузки датасета, подготовки данных, обучения моделей классификации и оценки их качества.

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.linear_model import LogisticRegression
from sklearn.svm import LinearSVC
from sklearn.metrics import accuracy_score
from sklearn.metrics import classification_report
from sklearn.metrics import confusion_matrix

revs = pd.read_csv("IMDB Dataset.csv")
print(revs.head())

revs["p/n"] = revs["sentiment"].map({ "positive": 1, "negative": 0 })
print(revs.head())
revs_train, revs_test = train_test_split(
    revs,
    test_size=0.5,
    random_state=42,
    stratify=revs["p/n"]
)

print("Размер обучающей выборки:", revs_train.shape)
print("Размер тестовой выборки:", revs_test.shape)
y_test = revs_test["p/n"]
model_nb = make_pipeline(
    CountVectorizer(),
    MultinomialNB()
)

model_nb.fit(revs_train["review"], revs_train["p/n"])

y_pred_nb = model_nb.predict(revs_test["review"])

print("Multinomial Naive Bayes")
print("Accuracy:", accuracy_score(y_test, y_pred_nb))
print("Classification report:")
print(classification_report(y_test, y_pred_nb))
print("Confusion matrix:")
print(confusion_matrix(y_test, y_pred_nb))
model_lr = make_pipeline(
    TfidfVectorizer(),
    LogisticRegression(max_iter=1000)
)
```

```

model_lr.fit(revs_train["review"], revs_train["p/n"])

y_pred_lr = model_lr.predict(revs_test["review"])

print("Logistic Regression")
print("Accuracy:", accuracy_score(y_test, y_pred_lr))
print("Classification report:")
print(classification_report(y_test, y_pred_lr))
print("Confusion matrix:")
print(confusion_matrix(y_test, y_pred_lr))


model_svc = make_pipeline(
    CountVectorizer(),
    LinearSVC(max_iter=5000)
)

model_svc.fit(revs_train["review"], revs_train["p/n"])

y_pred_svc = model_svc.predict(revs_test["review"])

print("LinearSVC")
print("Accuracy:", accuracy_score(y_test, y_pred_svc))
print("Classification report:")
print(classification_report(y_test, y_pred_svc))
print("Confusion matrix:")
print(confusion_matrix(y_test, y_pred_svc))
results = pd.DataFrame({
    "Модель": [
        "Multinomial Naive Bayes",
        "Logistic Regression",
        "LinearSVC"
    ],
    "Accuracy": [
        accuracy_score(y_test, y_pred_nb),
        accuracy_score(y_test, y_pred_lr),
        accuracy_score(y_test, y_pred_svc)
    ]
})

print(results)


review = ["This movie was very interesting and exciting"]
prediction = model_lr.predict(review)

if prediction[0] == 1:
    print("Положительный отзыв")
else:
    print("Отрицательный отзыв")

```